UNIVERSITÀ DEGLI STUDI DI MILANO

BREAST CANCER DIAGNOSIS

2025-2026

Lorenzo Guidi 41301A
Jaime Carnevale 32797A
Umberto Mitolo 41384A

CANCRO AL SENO

COS'È?

Il tumore al seno è una malattia in cui le cellule della ghiandola mammaria crescono in modo anomalo e incontrollato, formando un tumore che può invadere i tessuti vicini e, se maligno, diffondersi ad altre parti del corpo.

OBIETTIVI

- COMPRENDERE LA STRUTTURA DEL DATASET TRAMITE VISUALIZZAZIONE
- VALUTARE SE ALGORITMI DI CLUSTERING RIESCONO A SEPARARE NATURALMENTE LE DUE CLASSI
- ADDESTRARE UN CLASSIFICATORE PER DISTINGUERE TUMORI BENIGNI E MALIGNI
- COLLEGARE QUESTI PROCESSI AI MECCANISMI COGNITIVI DELLA PERCEZIONE.

FASI

1.VISUALIZZAZIONE DATI

2.CLUSTERING NON SUPERVISIONATO

3.CLASSIFICAZIONE SUPERVISIONATA

VISUALIZZAZIONE

IL NOSTRO DATASET

Per questo progetto abbiamo utilizzato un dataset messo a disposizione dal Winsconsin University Hospital, che contiene **569 istanze** che rappresentano le masse tumorali prelevate dalle pazienti. Per quanto riguarda il numero di **features** invece ne abbiamo **30** tutte di tipo **continuo**.
Come **classi** abbiamo:
-Maligno (M)
-Benigno (B)

FEATURES TOTALI

Elenco Completo delle 30 Features (Breast Cancer Wisconsin Diagnostic)

Mean (Media)	Standard Error (Errore Std)	Worst (Peggiore)
mean radius	radius error	worst radius
mean texture	texture error	worst texture
mean perimeter	perimeter error	worst perimeter
mean area	area error	worst area
mean smoothness	smoothness error	worst smoothness
mean compactness	compactness error	worst compactness
mean concavity	concavity error	worst concavity
mean concave points	concave points error	worst concave points
mean symmetry	symmetry error	worst symmetry
mean fractal dimension	fractal dimension error	worst fractal dimension

FEATURES SELEZIONATE

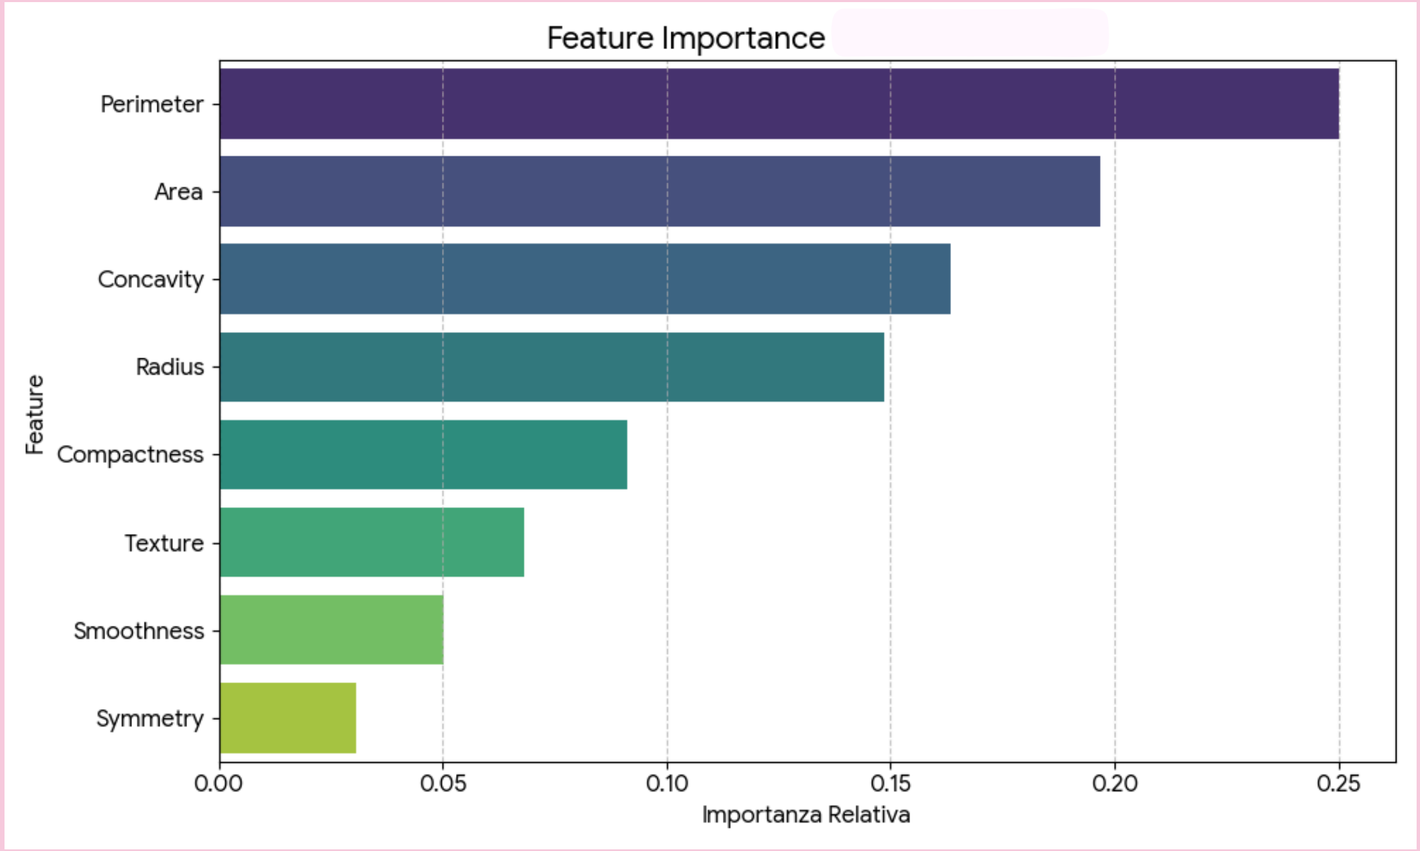

- PERIMETER
-AREA
-CONCAVITY
-RADIUS
-COMPACTNESS
-TEXTURE
-SMOOTHNESS
-SYMMETRY

DISTRIBUZIONE DEL TARGET

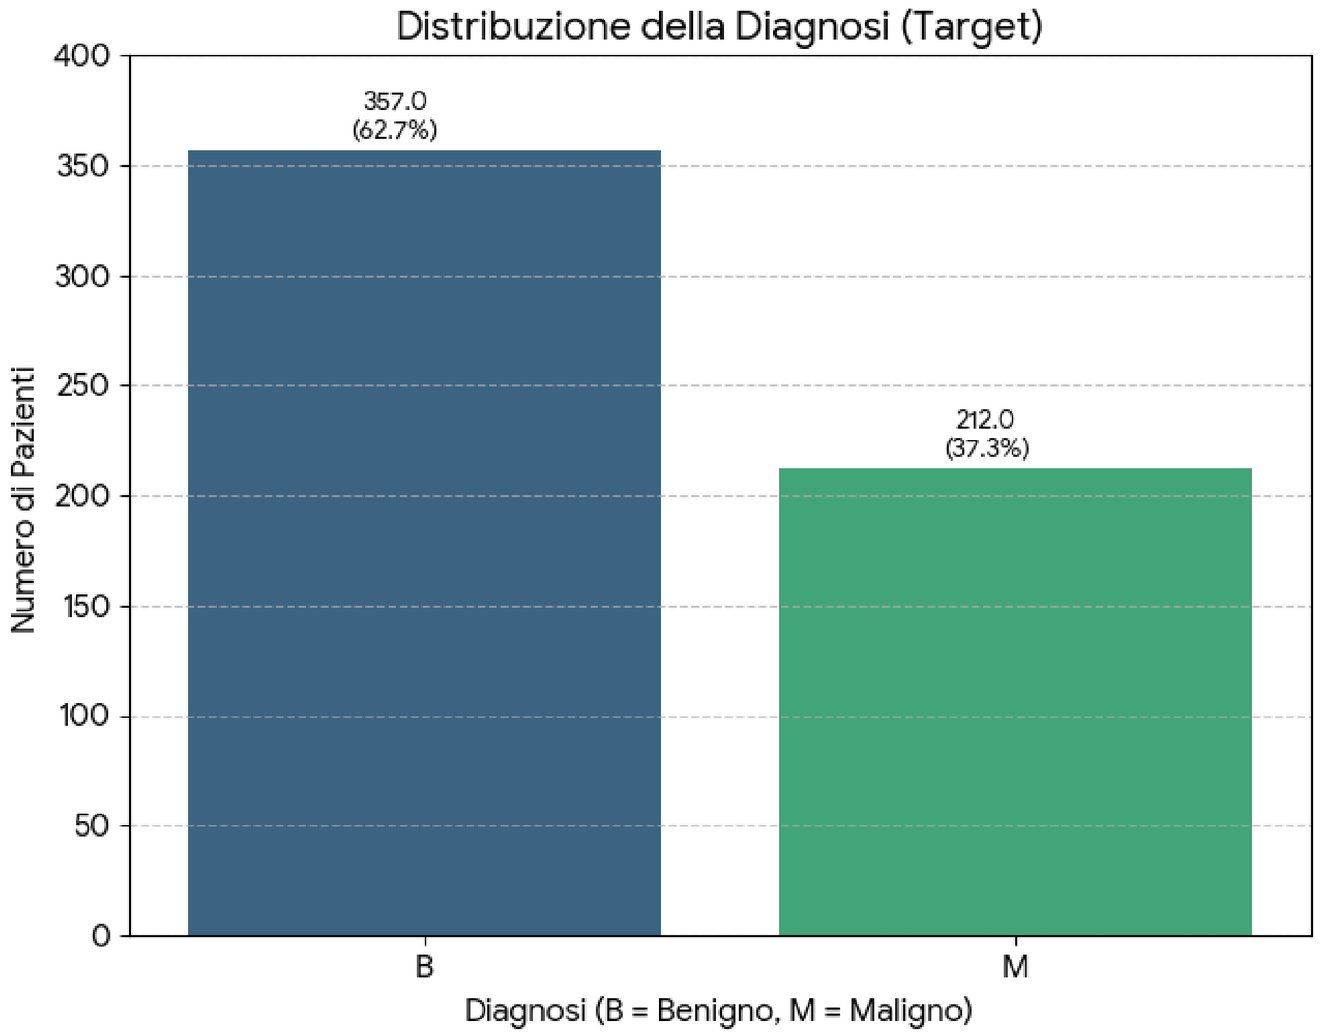

ISTOGRAMMA DELLE FEATURES SELEZIONATE

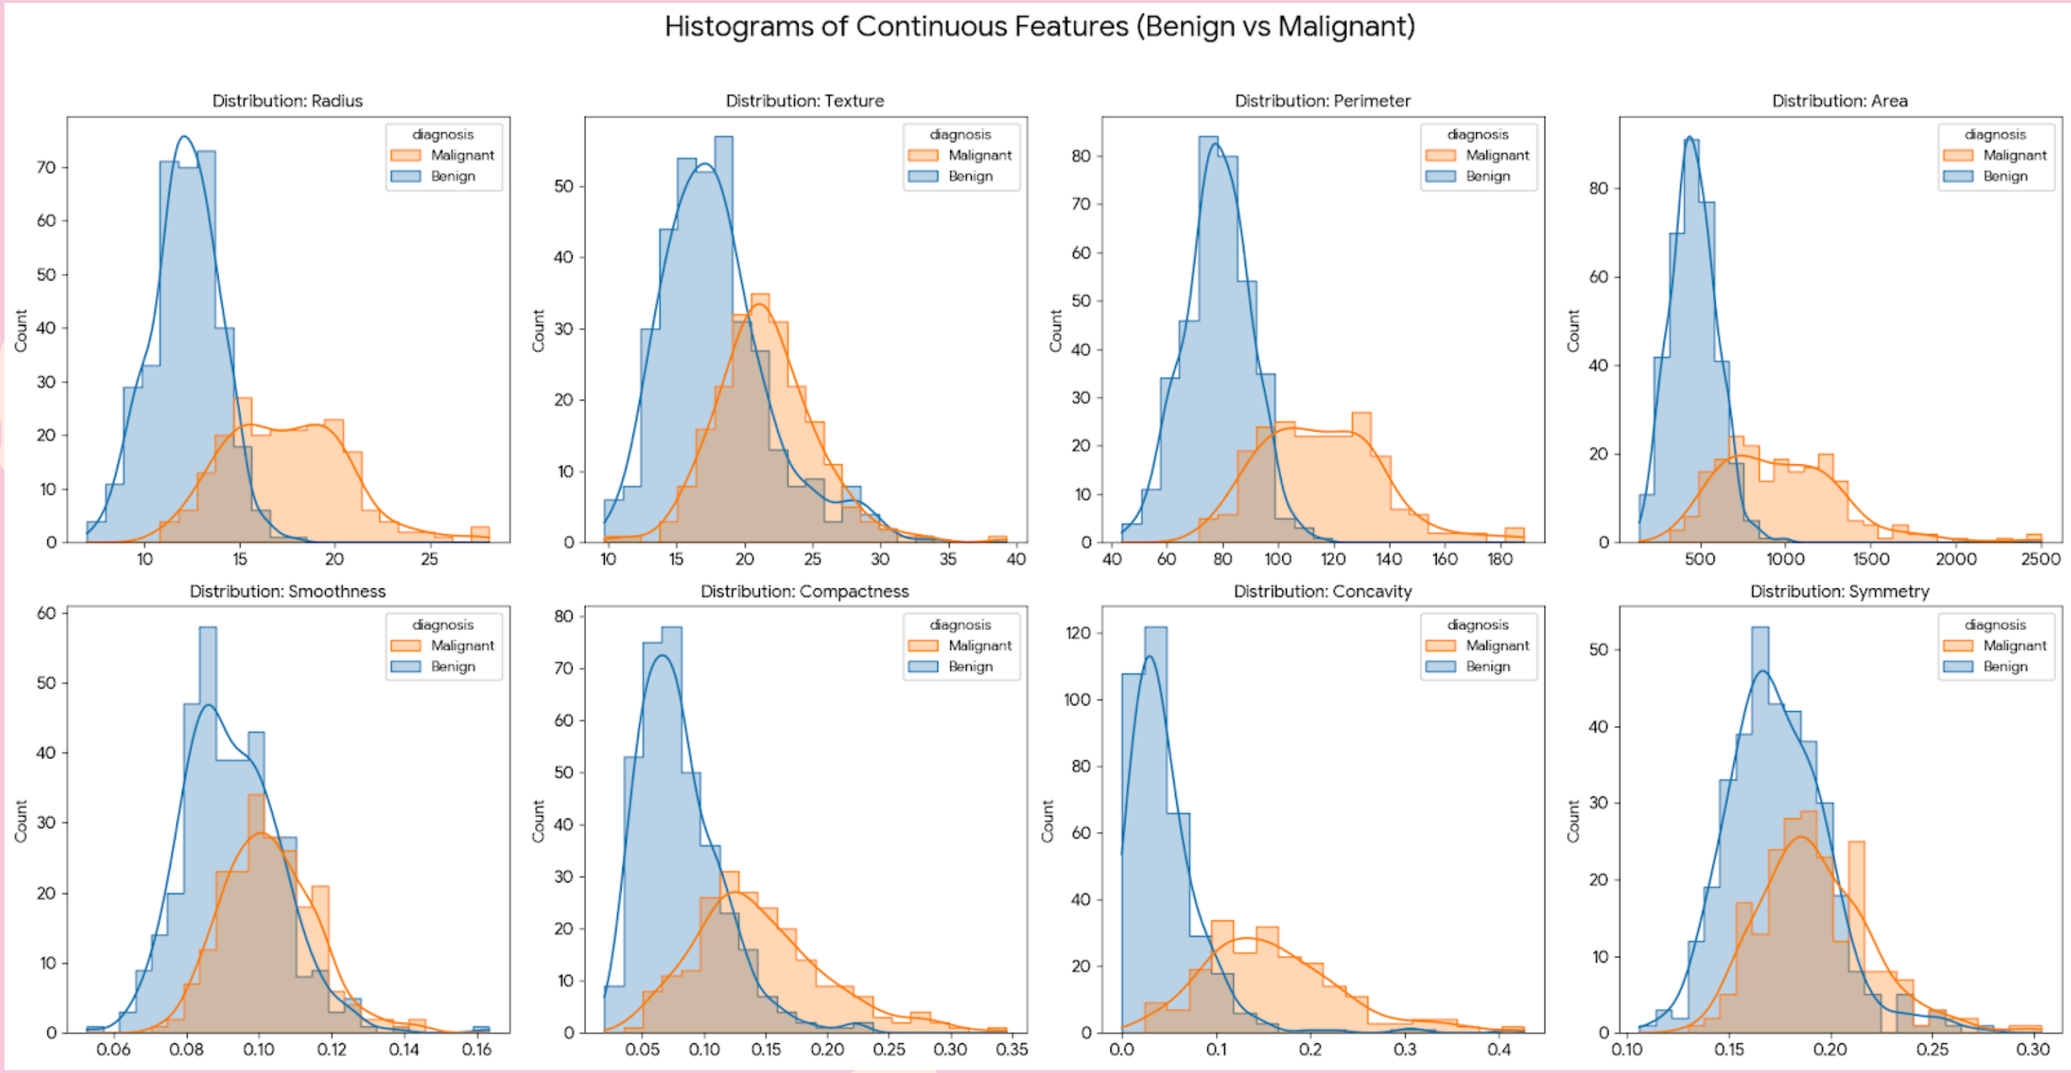

BOXPLOT

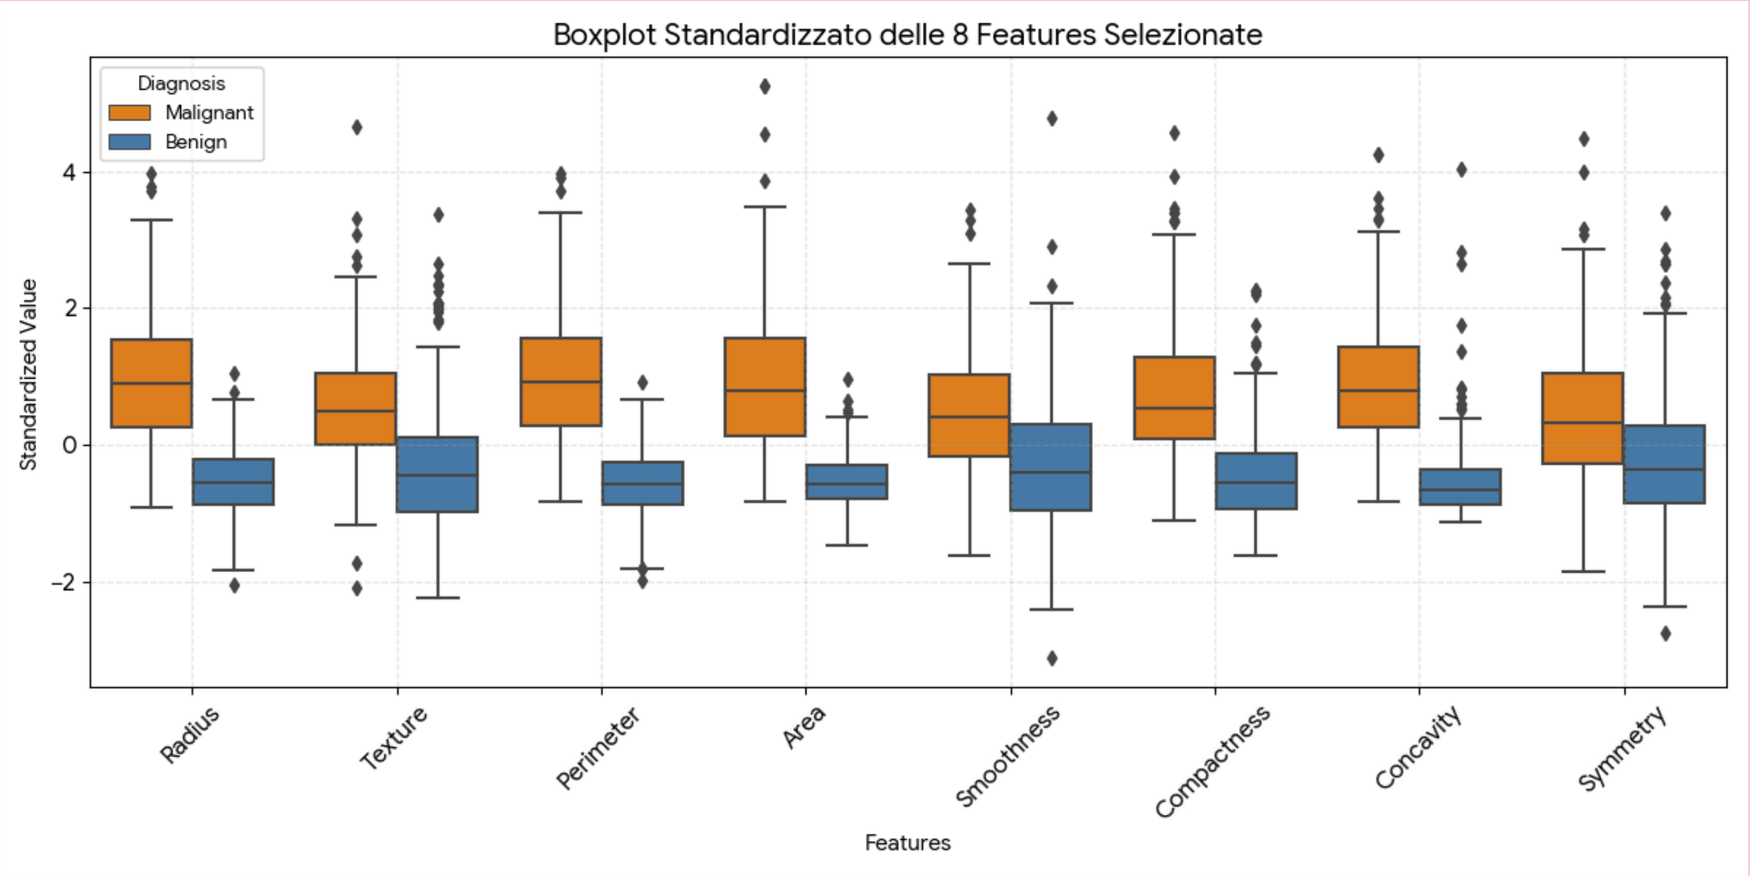
Boxplot Standardizzato delle 8 Features Selezionate
Diagnosis
Malignant
Benign
Standardized Value
4
2
0
−2
Radius
Texture
Perimeter
Area
Smoothness
Compactness
Concavity
Symmetry
Features

HEATMAP DELLE FEATURES SELEZIONATE

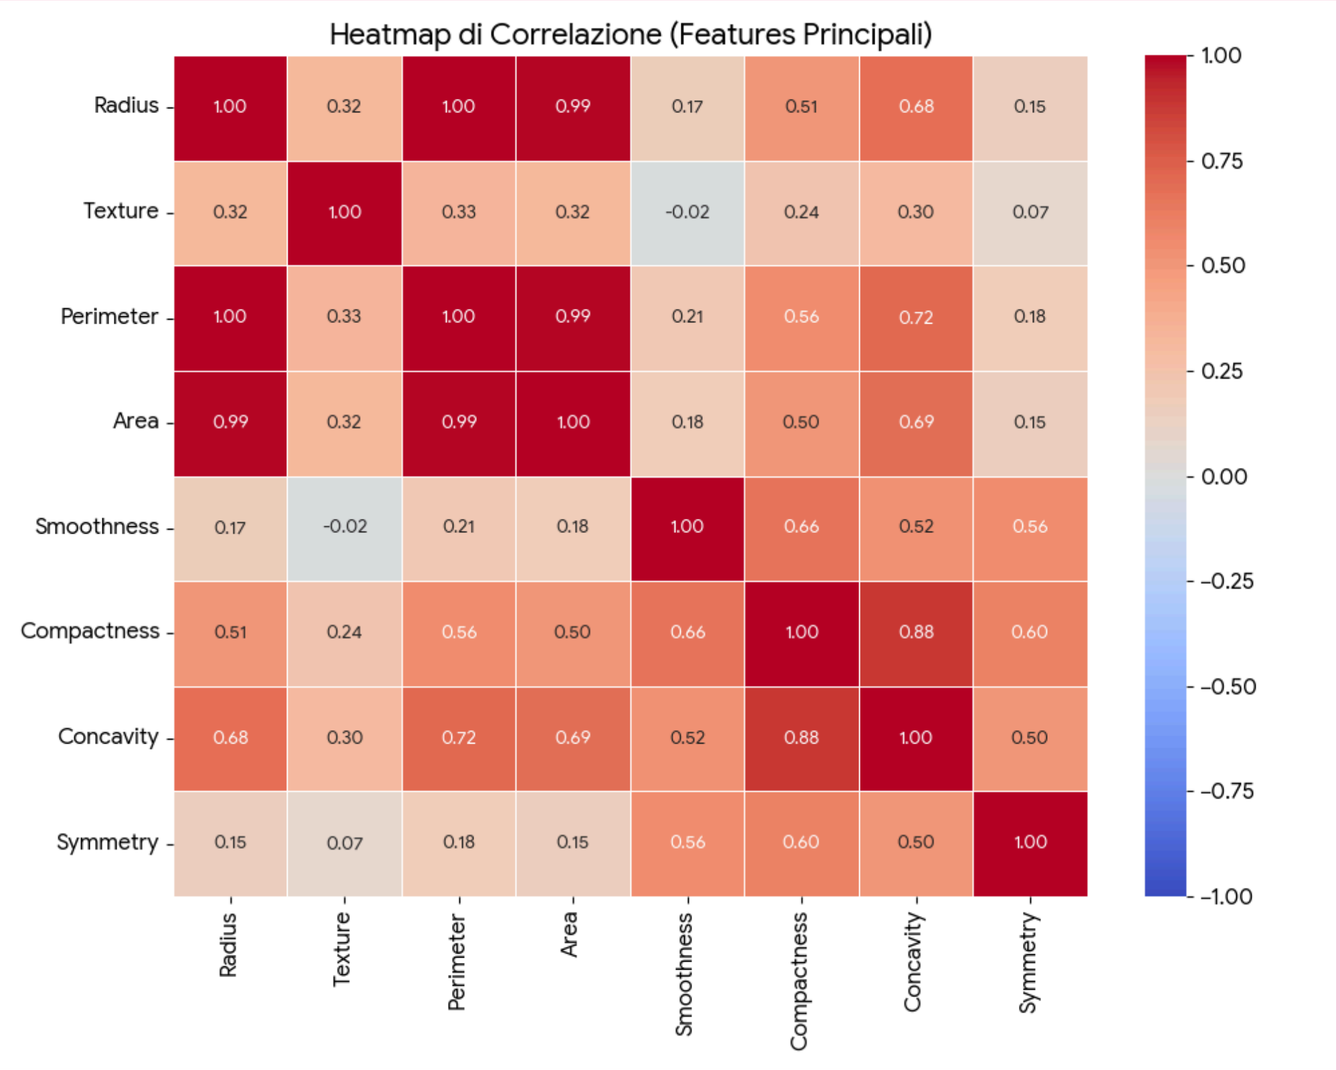

CLUSTERING

CON K-MEANS

DISTANZA EUCLIDEA

$$d(x, y) = \sqrt{(x_1 - y_1)^2 + (x_2 - y_2)^2 + \cdots + (x_n - y_n)^2}$$

ASSIGNMENT STEP

UPDATE STEP

PERCHE' USARE K-MEANS?

1) FACILMENTE INTERPRETABILE

2) FUNZIONA BENISSIMO CON FEATURE CONTINUE

3) RIFLETTE I PRINCIPI PERCETTIVI DELLA GESTALT

4) COMPUTAZIONALMENTE LEGGERO

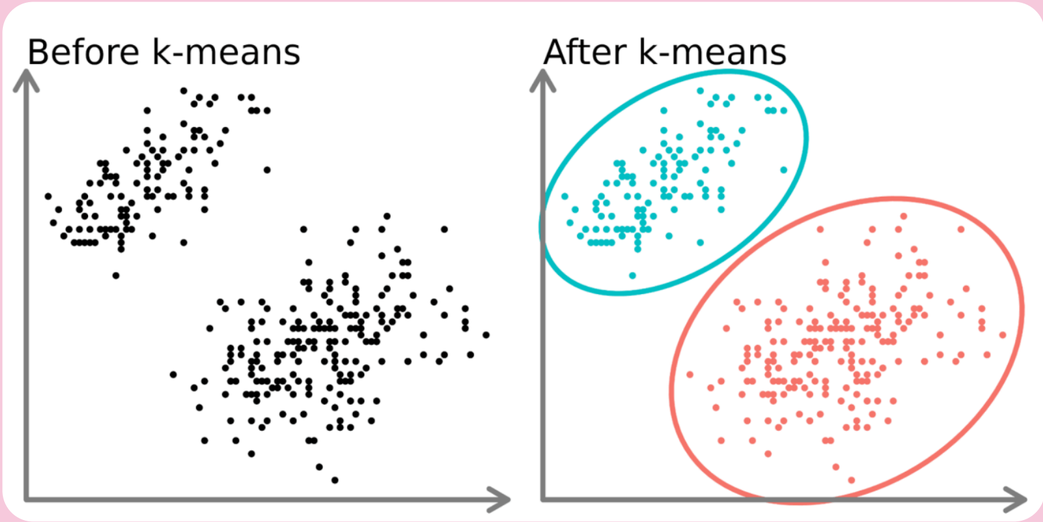

K-MEANS

PREPROCESSING: STANDARDIZZAZIONE DEI DATI

```
from sklearn.preprocessing import StandardScaler
scaler = StandardScaler()
X_scaled = scaler.fit_transform(X)
```

ADDESTRAMENTO ED ASSEGNAZIONE DEI CLUSTER

```
from sklearn.cluster import KMeans
kmeans = KMeans(n_clusters=2, random_state=42)
labels = kmeans.fit_predict(X_scaled)
```

PCA SCATTER PLOT

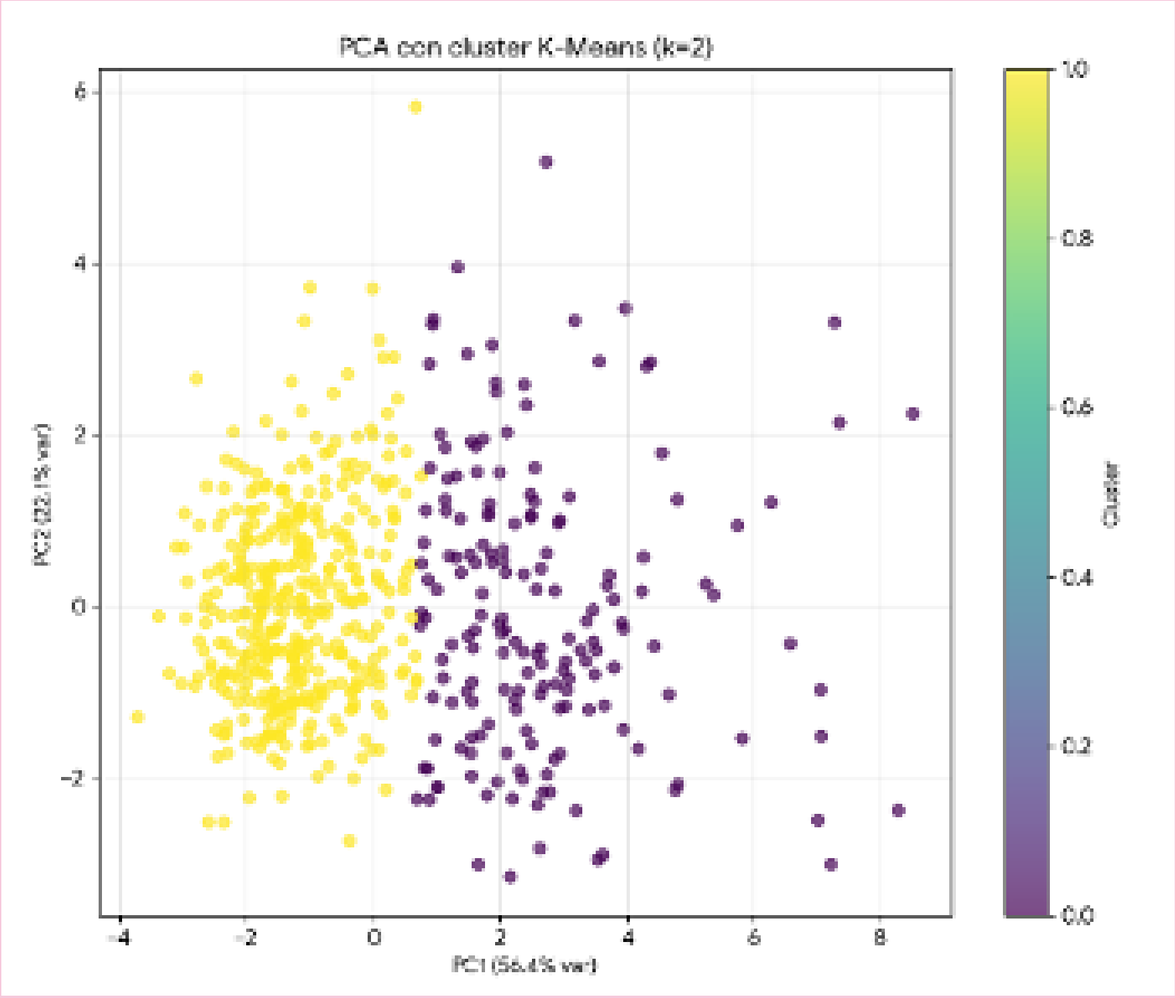

PCA SCATTER PLOT CON CENTROIDI

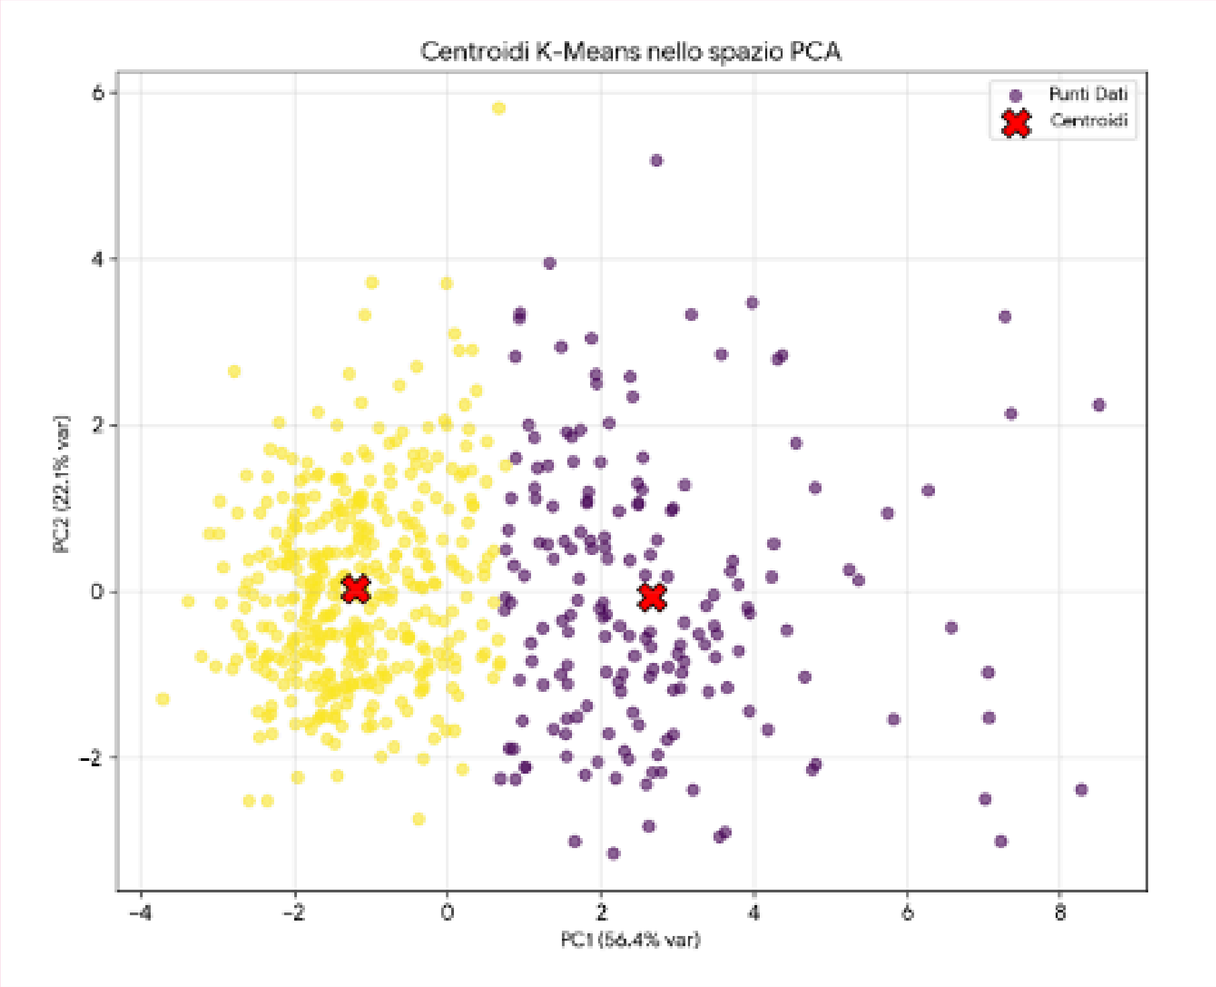

ELBOW PLOT (K VS INERTIA)

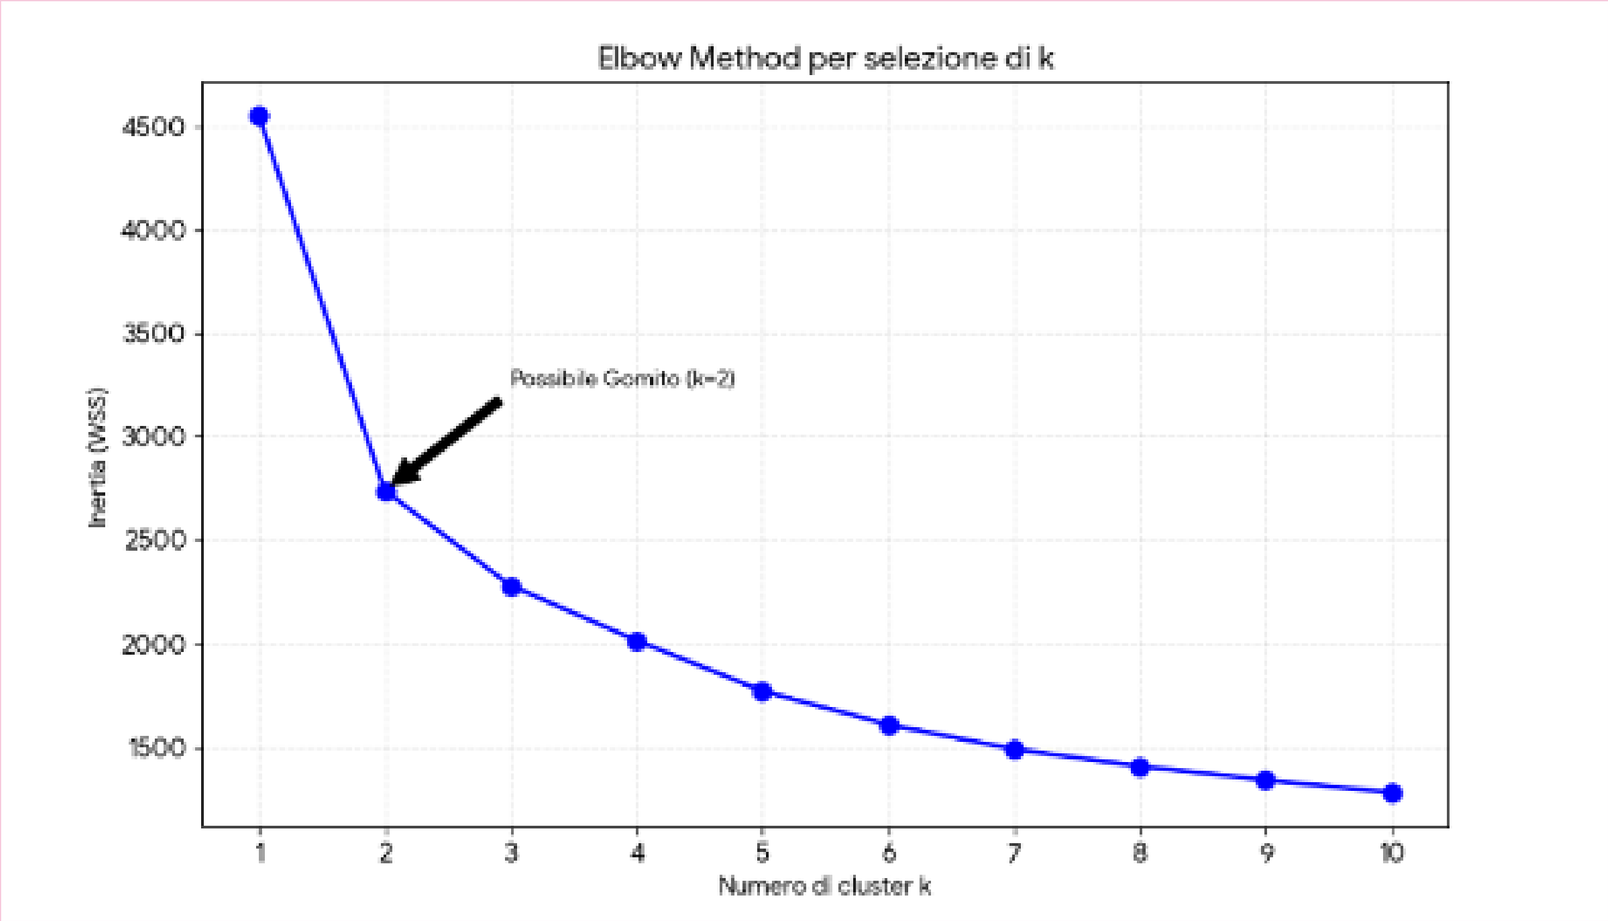

SILHOUETTE PLOT

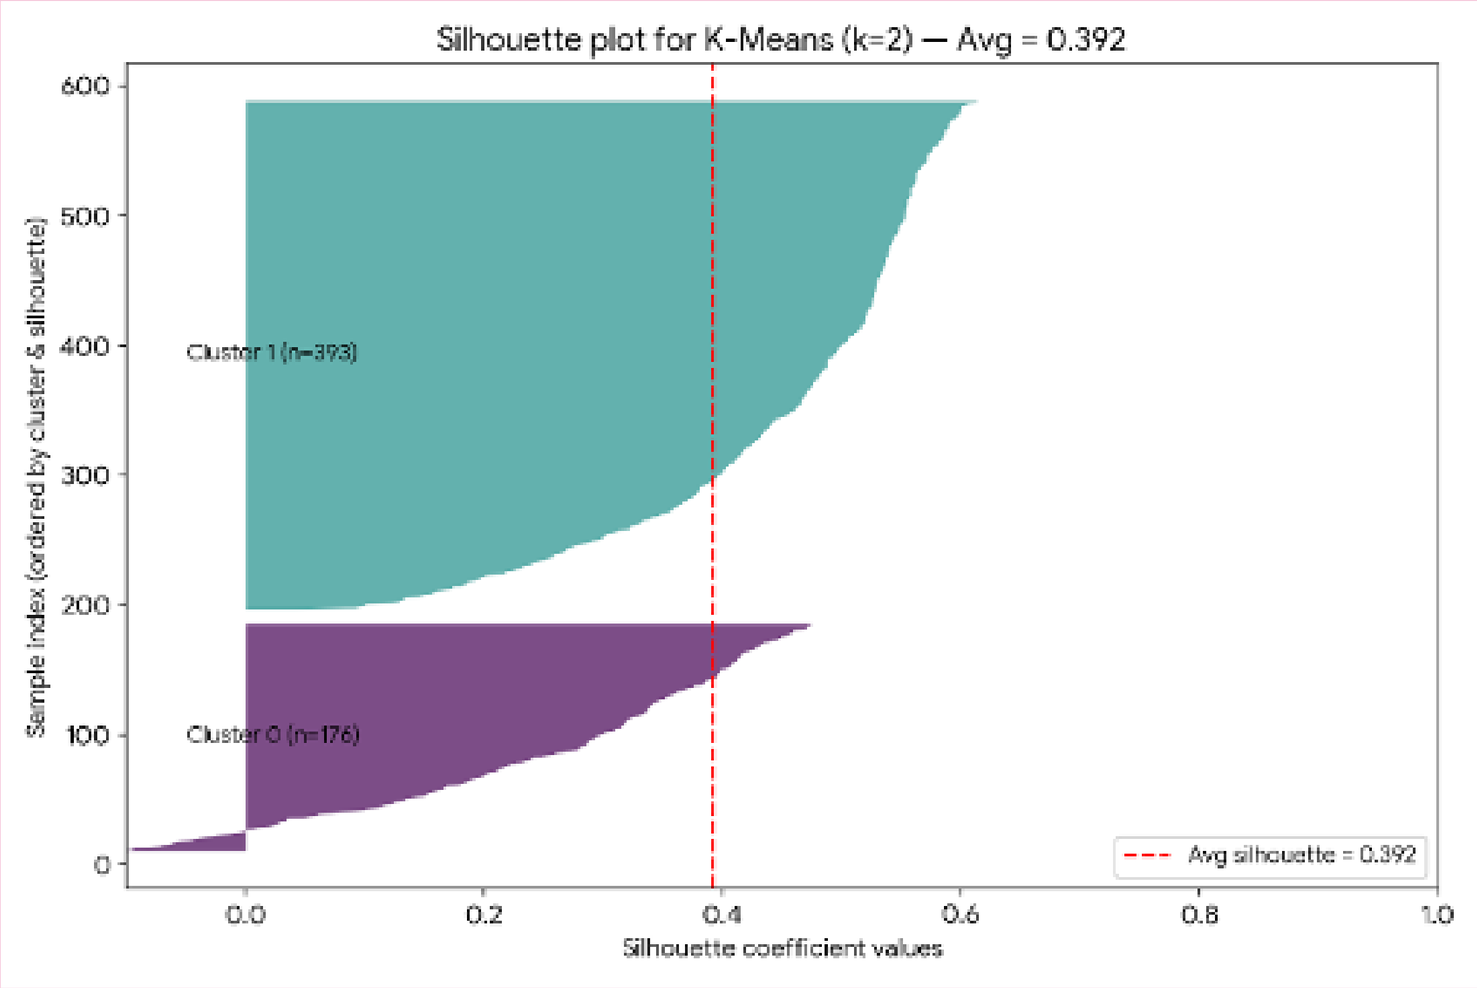

CLASSIFICAZIONE

PERCHE' USARE RANDOM FOREST?

1) OTTIMO PER DATASET PICCOLI COME IL NOSTRO E CON CON POCHE FEATURES

2) EVITA L'OVERFITTING

3) FACILE DA INTERPRETARE

4) OTTIMO ANCHE CON DATASET SBILANCIATI

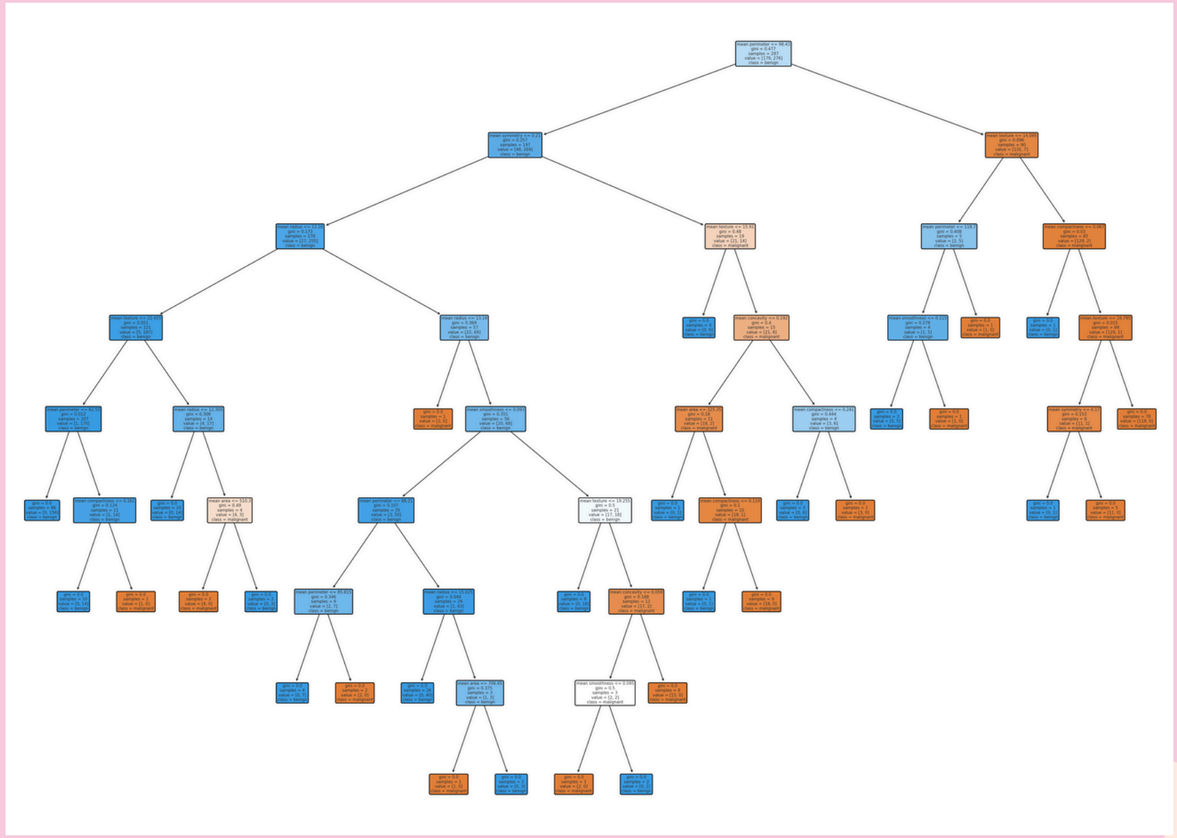

ALGORITMO RANDOM FOREST

```python
from sklearn.datasets import load_breast_cancer
from sklearn.model_selection import train_test_split
from sklearn.ensemble import RandomForestClassifier
from sklearn.metrics import classification_report, confusion_matrix
```

IMPORT INDISPENSABILI

```python
rf_standard = RandomForestClassifier(
    n_estimators=150,        # 150 alberi
    random_state=42          # per riproducibilità
)

# Addestramento
rf_standard.fit(X_train, y_train)
```

COSTRUZIONE RANDOM FOREST

```python
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, stratify=y, random_state=42
)
```

DIVISIONE DEL SET

```python
print("\n=== CLASSIFICATION REPORT (STANDARD) ===")
print(classification_report(y_test, y_pred, target_names=["malignant", "benign"]))

print("\n=== CONFUSION MATRIX (STANDARD) ===")
print(confusion_matrix(y_test, y_pred))


print("\n=== METRICHE PRINCIPALI ===")
print("Accuracy :", accuracy_score(y_test, y_pred))
```

VALUTAZIONE

METRICHE

PRECISIONE

$$\text{Precision} = \frac{TP}{TP + FP}$$

F1-SCORE

$$\text{F1} = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}$$

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$

ACCURATEZZA

RECALL

$$\text{Recall} = \frac{TP}{TP + FN}$$

MATRICE DI CONFUSIONE MODELLO STANDARD

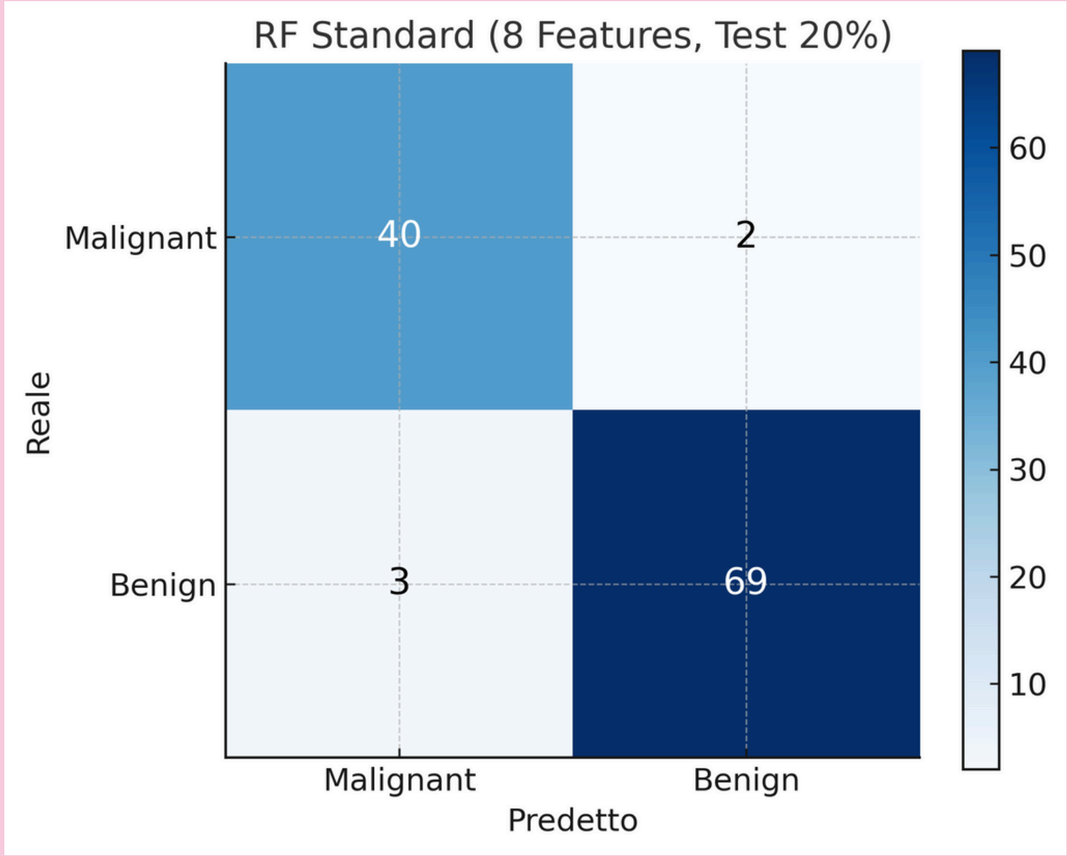

CONCLUSIONI

1. ANALISI ESPLORATIVA CON HEATMAP E BOXPLOT HA RIVELATO CHE IL PROBLEMA DIAGNOSTICO È UN PROBLEMA GEOMETRICO
2. CON ALGORITMO KMEANS È STATA CONFERMATA L'ESISTENZA DI UNA STRUTTURA BINARIA NATURALE (TUTTAVIA C'È UNA "ZONA AMBIGUA")
3. SIAMO RIUSCITI A DISTINGUERE TUMORI BENIGNI E MALIGNI TRAMITE RANDOM FOREST
4. LA VISUALIZZAZIONE PCA CI MOSTRA COME IL KMEANS COSTRUISCA CATEGORIE MENTALI BASATE SULLA SIMILARITÀ, PROPRIO COME PROPRIO COME LA MENTE UMANA (= CATEGORIZZAZIONE)

FONTI

UCI MACHINE LEARNING REPOSITORY – BREAST CANCER WISCONSIN (DIAGNOSTIC)

MACQUEEN, J. (1967). SOME METHODS FOR CLASSIFICATION AND ANALYSIS OF MULTIVARIATE OBSERVATIONS.

BISHOP, C. (2006). PATTERN RECOGNITION AND MACHINE LEARNING

ROUSSEEUW, P. J. (1987). SILHOUETTES: A GRAPHICAL AID..., JOURNAL OF COMPUTATIONAL AND APPLIED MATHEMATICS

SCIKIT-LEARN DOCUMENTAZIONE UFFICIALE